

Laporan Bagian G (M1)

Daerah yang Paling Banyak Terkena COVID-19 di Indonesia (2022)

Kelompok-EDA_AI01 — Mata Kuliah Exploratory Data Analysis 2026-1 (A)



Anggota:

Abdul Aziz Al Palembani

Fahri Mulyadi

Lukman Maruf

Nicha Amelia SRG

PROGRAM STUDI TEKNIK INFORMATIKA

STT TERPADU NURUL FIKRI

DEPOK 2026

G1 — Pertanyaan Analisis

Pertanyaan utama yang ingin dijawab dengan data ini adalah sebagai berikut.

Daerah seperti apa di Indonesia yang paling banyak terkena COVID-19 pada tahun 2022 (1 Januari sampai 15 September)?

Pertanyaan utama ini dipecah menjadi empat pertanyaan yang lebih kecil. Setiap pertanyaan sudah diperiksa dengan tiga uji. Uji kolom memastikan kolom yang menjawabnya jelas disebut namanya. Uji bentuk jawaban memastikan jawabannya berupa angka, peringkat, perbandingan, atau sebaran. Uji tindak lanjut memastikan hasilnya bisa dipakai untuk mengambil keputusan oleh pihak tertentu.

#	Pertanyaan	Kolom yang Dipakai	Bentuk Jawaban	Tindak Lanjut
1	Provinsi mana yang paling banyak dan paling sedikit terkena COVID-19?	Location, New Cases, Population, Date	Peringkat 5 teratas dan 5 terbawah	Menentukan provinsi yang dicek lebih dulu kesiapan tes dan rumah sakitnya, oleh Kemenkes dan Dinas Kesehatan provinsi
2	Apakah provinsi yang lebih padat penduduknya juga lebih banyak terkena?	Population Density, New Cases, Population	Perbandingan 3 kelompok kepadatan dan sebaran tiap provinsi	Menentukan apakah kepadatan penduduk jadi pertimbangan awal memilih provinsi prioritas, oleh Kemenkes dan pemerintah provinsi
3	Pulau mana yang paling banyak terkena COVID-19?	Island, New Cases, Population	Perbandingan 7 pulau	Menentukan apakah persiapan dan logistik dibedakan per pulau, oleh Kemenkes dan Dinas Kesehatan provinsi

#	Pertanyaan	Kolom yang Dipakai	Bentuk Jawaban	Tindak Lanjut
4	Dari setiap 1.000 orang yang tercatat terkena, berapa yang meninggal, dan apakah berbeda antarpulau?	Island, New Cases, New Deaths	Perbandingan 7 pulau	Menentukan pulau yang layanan rujukan dan perawatan intensifnya perlu diperkuat, oleh Kemenkes dan Dinas Kesehatan provinsi

Arti Istilah yang Dipakai

Istilah	Arti
Terkena	Kasus COVID-19 yang tercatat di data (kolom New Cases).
Per 1 juta penduduk	Jumlah kasus dibagi jumlah penduduk, lalu dikali 1.000.000. Tujuannya agar provinsi besar dan provinsi kecil bisa dibandingkan secara adil.
Kelompok kepadatan	Sebanyak 34 provinsi diurutkan dari yang paling jarang sampai paling padat penduduknya, lalu dibagi menjadi 3 kelompok hampir sama besar: Jarang (12 provinsi), Sedang (11 provinsi), dan Padat (11 provinsi).
Nilai tengah (median)	Nilai yang berada di tengah kalau semua provinsi diurutkan. Dipakai karena DKI Jakarta angkanya sangat jauh di atas provinsi lain, sehingga rata-rata biasa bisa menyesatkan.
Kematian per 1.000 kasus	Jumlah kematian dibagi jumlah kasus tercatat, lalu dikali 1.000.

Pertanyaan yang Dicoret

Pertanyaan	Alasan
Apakah vaksinasi menurunkan angka kematian antarprovinsi?	Gagal uji kolom, karena tidak ada kolom vaksinasi di dataset

Hasil dari semua pertanyaan hanya menunjukkan pola, bukan sebab-akibat. Jumlah kasus yang tercatat juga dipengaruhi banyaknya orang yang dites di tiap daerah, sehingga provinsi yang lebih banyak mengetes bisa tampak memiliki kasus lebih banyak.

G2 — Provenans Data

Butir	Isi
Nama sumber	Hendratno (kompilator, Kaggle). Data asli dari covid19.go.id, kemendagri.go.id, bps.go.id, dan bnpb-inacovid19.hub.arcgis.com
Tautan	https://www.kaggle.com/datasets/hendratno/covid19-indonesia
Tanggal pengambilan	28 September 2026
Lisensi	CC BY-NC-SA 4.0 (tertulis di Data Card Kaggle)
Kalimat sitasi	Hendratno. COVID-19 Indonesia Dataset. Kaggle. Diakses 28 September 2026. Data dikompilasi dari covid19.go.id, kemendagri.go.id, bps.go.id, dan bnpb-inacovid19.hub.arcgis.com. Lisensi CC BY-NC-SA 4.0.

Berkas yang dipakai adalah covid_19_indonesia_time_series_all.csv, berisi 31.822 baris dan 38 kolom, mencakup 1 Maret 2020 sampai 16 September 2022, untuk 34 provinsi ditambah satu baris tingkat nasional. Berkas mentah tidak disimpan di repositori. Folder data/raw/ masuk .gitignore, dan setiap anggota mengunduh sendiri dari tautan Kaggle di atas.

Lisensi CC BY-NC-SA 4.0 punya tiga ketentuan. Sumber wajib disebutkan setiap kali data dipakai. Data tidak boleh dipakai untuk tujuan komersial. Kalau hasil olahan data dibagikan ke publik, hasil olahan itu harus memakai lisensi yang sama.

G3 — Kamus Data

Kamus data dibuat untuk seluruh 38 kolom dan disimpan sebagai `data_dictionary.csv` di repositori. Setiap kolom dijelaskan artinya, skala pengukurannya, kategori data pribadinya, dan tindakan penanganannya.

Seluruh kolom dikategorikan **bukan data pribadi**. Data berupa hitungan gabungan per wilayah (provinsi) serta keterangan wilayah atau waktu, seperti tanggal, pulau, kepadatan, dan luas wilayah. Dataset ini tidak memuat nama, NIK, alamat, usia, atau jenis kelamin individu. Kolom Longitude dan Latitude hanya menunjuk titik pusat provinsi, bukan lokasi seseorang.

Kolom yang dipakai langsung untuk menjawab pertanyaan adalah Date, Location, Location Level, New Cases, New Deaths, Population, Population Density, dan Island. Kolom lain tetap dicatat di kamus data tetapi tidak dipakai dalam perhitungan. Kolom Date tersimpan sebagai teks berformat bulan/hari/tahun dan diubah ke tipe tanggal sebelum diproses.

G4 — Penanganan Data dan Nilai k

Langkah Penanganan

- Data difilter ke tingkat provinsi saja. Baris tingkat nasional (Indonesia) dibuang agar tidak terhitung ganda.
- Data difilter ke tahun 2022, menghasilkan 8.770 baris provinsi-hari untuk 34 provinsi, dari 1 Januari sampai 15 September 2022.
- Kasus dan kematian dijumlahkan per provinsi untuk seluruh periode 2022, sehingga satu baris mewakili satu provinsi, bukan satu provinsi per hari.
- Hasil dibagi jumlah penduduk dan dikali 1.000.000 untuk mendapatkan kasus dan kematian per 1 juta penduduk. Angka per pulau dihitung dari total kasus dan total penduduk seluruh provinsi di pulau itu.

Nilai k

Nilai k adalah jumlah kasus atau kematian paling sedikit yang diwakili oleh satu angka yang ditampilkan. Semakin kecil k, semakin mudah angka itu mengarah ke satu kejadian atau satu orang tertentu.

Sebelum digabung (satu baris mewakili satu provinsi pada satu hari, 8.770 baris):

Ukuran	Nilai
k kasus harian	1
k kematian harian	1
Baris dengan tepat 1 kasus baru	802
Baris dengan 1–4 kasus baru	2.064
Baris dengan tepat 1 kematian baru	1.032
Baris dengan kematian lebih dari 0	2.599
Baris dengan 1–4 kematian	1.953

Sesudah digabung (satu baris mewakili satu provinsi untuk seluruh periode 2022, 34 baris):

Ukuran	Nilai	Provinsi
k kasus	2.102	Gorontalo
k kematian	20	Papua

Batas yang dipakai adalah k minimal 5. Dengan k kasus 2.102 dan k kematian 20, keduanya jauh di atas batas, sehingga status penanganan data dinyatakan **LULUS**. Karena data harian

memuat angka sekecil 1, laporan ini hanya menampilkan total per provinsi atau per pulau untuk seluruh periode. Angka harian per provinsi tidak pernah ditampilkan.

Tabel yang benar-benar ditampilkan di laporan (per pulau dan per kelompok kepadatan) juga diperiksa. Angka paling kecil di tabel itu adalah 6.630 kasus (Maluku) dan 48 kematian (Papua), keduanya tetap jauh di atas batas 5. Semua nilai k tercatat di `data/processed/catatan_k.csv`.

G5 — Daftar Periksa Sebelum git push


Butir	Status
data/raw/ masuk .gitignore dan tidak ikut ter-commit	Terpenuhi
Tidak ada nama, NIK, nomor telepon, surel, atau alamat pada berkas mana pun	Terpenuhi
Keluaran sel yang sempat menampilkan data pribadi sudah dibersihkan	Terpenuhi
Garam hash tidak tertulis di dalam notebook	Tidak berlaku
Kamus data memuat kategori dan tindakan untuk setiap kolom	Terpenuhi
Nilai k pada data yang diunggah sudah dihitung dan dicatat	Terpenuhi
Bila masih ragu, repositori dibuat privat	—

Hasil dan Jawaban (Q1–Q4)

Semua angka di bagian ini berupa total per provinsi atau per pulau untuk periode 1 Januari sampai 15 September 2022. Setiap grafik disertai cara membacanya.

Q1 — Provinsi Mana yang Paling Banyak dan Paling Sedikit Terkena?

Cara membaca: semakin panjang batang, semakin besar bagian penduduk provinsi itu yang tercatat terkena COVID-19. Batang merah adalah 5 provinsi terbanyak, batang biru adalah 5 provinsi tersedikit.




Peringkat	Provinsi	Pulau	Kasus per 1 Juta Penduduk
1	DKI Jakarta	Jawa	50.452

Peringkat	Provinsi	Pulau	Kasus per 1 Juta Penduduk
2	Banten	Jawa	18.750
3	Daerah Istimewa Yogyakarta	Jawa	18.538
4	Kalimantan Utara	Kalimantan	14.616
5	Kalimantan Timur	Kalimantan	14.269
34	Aceh	Sumatera	1.069
33	Nusa Tenggara Barat	Nusa Tenggara	1.601
32	Gorontalo	Sulawesi	1.780
31	Maluku Utara	Maluku	1.904
30	Sulawesi Barat	Sulawesi	2.072

Jawaban: DKI Jakarta paling banyak terkena, dengan sekitar 50.452 kasus per 1 juta penduduk atau kira-kira 1 dari 20 penduduk. Aceh paling sedikit, dengan sekitar 1.069 kasus per 1 juta penduduk atau kira-kira 1 dari 936 penduduk. Selisih keduanya sekitar 47 kali lipat.

Q2 — Apakah Provinsi yang Lebih Padat Juga Lebih Banyak Terkena?

Cara membaca: 34 provinsi dibagi menjadi 3 kelompok menurut kepadatan penduduknya. Satu titik adalah satu provinsi, dan semakin tinggi titiknya semakin banyak penduduknya yang terkena. Garis putus-putus adalah nilai tengah tiap kelompok, sehingga antar kelompok bisa dibandingkan langsung.



Kelompok	Kepadatan (jiwa/km ²)	Jumlah Provinsi	Nilai Tengah Kasus per 1 Juta
Jarang	8,6 – 69,8	12	4.159
Sedang	84,0 – 201,8	11	3.035
Padat	203,8 – 16.334,3	11	8.641

Jawaban: ya, tetapi tidak rapi. Kelompok provinsi paling padat punya nilai tengah paling tinggi (8.641 per 1 juta), sekitar dua kali kelompok paling jarang (4.159). Namun kelompok sedang justru paling rendah (3.035), jadi angkanya tidak naik bertahap mengikuti kepadatan.

Ada juga pengecualian yang terlihat di grafik. Kalimantan Utara dan Kalimantan Timur sangat jarang penduduknya, tetapi termasuk 5 provinsi dengan kasus tertinggi. Sebaliknya, Jawa Tengah dan Nusa Tenggara Barat termasuk kelompok padat, tetapi angkanya rendah. Artinya kepadatan ikut menjelaskan, tetapi bukan satu-satunya faktor, dan data ini tidak cukup untuk menjelaskan sebab pengecualian tersebut.

Q3 — Pulau Mana yang Paling Banyak Terkena?

Cara membaca: angka di ujung batang adalah jumlah kasus tercatat untuk setiap 1 juta penduduk di pulau itu. Angka dalam kurung adalah jumlah provinsi di pulau tersebut.




Pulau	Jumlah Provinsi	Total Kasus	Total Penduduk	Kasus per 1 Juta
Jawa	6	1.631.428	147.203.954	11.083
Kalimantan	5	114.175	16.216.750	7.041
Nusa Tenggara	3	91.044	14.897.739	6.111
Papua	2	24.063	5.481.049	4.390
Sulawesi	6	77.166	20.400.432	3.783
Sumatera	10	190.154	57.830.696	3.288
Maluku	2	6.630	3.154.900	2.101

Jawaban: Pulau Jawa paling banyak terkena (sekitar 11.083 per 1 juta), disusul Kalimantan (7.041) dan Nusa Tenggara (6.111). Maluku paling rendah. Namun sebagian besar angka Jawa berasal dari DKI Jakarta. Kalau DKI Jakarta dikeluarkan, angka Jawa turun menjadi sekitar 7.951 per 1 juta, hanya sedikit di atas Kalimantan.

Q4 — Dari Setiap 1.000 Kasus, Berapa yang Meninggal?

Cara membaca: semakin panjang batang, semakin banyak yang meninggal dari setiap 1.000 kasus tercatat. Garis putus-putus adalah rata-rata seluruh Indonesia, yaitu 6,4 kematian per 1.000 kasus. Pulau di sebelah kanan garis berada di atas rata-rata nasional.



Pulau	Jumlah Provinsi	Total Kasus	Total Kematian	Kematian per 1.000 Kasus
Sumatera	10	190.154	2.163	11,4
Nusa Tenggara	3	91.044	934	10,3
Maluku	2	6.630	61	9,2
Sulawesi	6	77.166	636	8,2
Kalimantan	5	114.175	716	6,3
Jawa	6	1.631.428	9.125	5,6
Papua	2	24.063	48	2,0

Jawaban: ya, berbeda cukup jauh. Pulau dengan kasus terbanyak bukan yang paling mematikan per kasus. Sumatera paling tinggi (sekitar 11,4 kematian per 1.000 kasus), sedangkan Jawa lebih rendah (5,6) dan Papua paling rendah (2,0). Perbedaan ini bisa mencerminkan kondisi layanan kesehatan, tetapi juga bisa karena perbedaan banyaknya tes:

di daerah yang jarang mengetes, kasus ringan banyak tidak tercatat sehingga angka kematian per kasus tampak lebih tinggi.

Kesimpulan

Pertanyaan utama laporan ini adalah daerah seperti apa yang paling banyak terkena COVID-19 di Indonesia pada tahun 2022. Berdasarkan keempat pertanyaan, jawabannya adalah **daerah yang padat penduduknya dan berada di Pulau Jawa, terutama DKI Jakarta**. Namun polanya tidak rapi, dan ada beberapa pengecualian yang penting.

Pertanyaan	Temuan Utama
Q1. Provinsi	DKI Jakarta paling banyak (50.452 per 1 juta), Aceh paling sedikit (1.069 per 1 juta), selisih sekitar 47 kali lipat.
Q2. Kepadatan	Kelompok paling padat punya nilai tengah tertinggi (8.641 per 1 juta), tetapi kelompok sedang justru terendah, dan ada pengecualian seperti Kalimantan Utara dan Kalimantan Timur.
Q3. Pulau	Jawa tertinggi (11.083 per 1 juta), tetapi tanpa DKI Jakarta hanya sedikit di atas Kalimantan.
Q4. Kematian per kasus	Sumatera tertinggi (11,4 per 1.000 kasus), Jawa 5,6, Papua terendah (2,0). Pulau dengan kasus terbanyak bukan yang paling mematikan per kasus.

Hasil ini cocok dipakai untuk menentukan provinsi dan pulau mana yang dicek lebih dulu dalam kesiapsiagaan, sesuai tindak lanjut pada G1. Namun hasilnya hanya menunjukkan pola, bukan sebab-akibat.

Catatan Keterbatasan

- Hasil hanya menunjukkan pola, bukan sebab-akibat.
- Jumlah kasus yang tercatat dipengaruhi banyaknya tes di tiap provinsi. Provinsi yang lebih banyak mengetes tampak punya kasus lebih banyak, dan angka kematian per 1.000 kasus bisa tampak lebih tinggi di daerah yang jarang mengetes.
- Dataset tidak memuat data vaksinasi, usia, jenis kelamin, kebijakan, atau fasilitas kesehatan, sehingga tidak bisa menjelaskan alasan di balik perbedaan antardaerah.
- DKI Jakarta angkanya jauh di atas provinsi lain, sehingga angka Pulau Jawa sebagian besar dipengaruhi Jakarta.
- Pulau Maluku dan Papua masing-masing hanya terdiri dari 2 provinsi, sehingga angkanya mudah berubah oleh satu provinsi saja.
- Periode yang dipakai hanya 1 Januari sampai 15 September 2022, bukan setahun penuh, dan hanya mewakili satu fase pandemi.
- Gorontalo dan Sulawesi Barat memiliki data 2022 yang berakhir satu hari lebih awal, yaitu pada 14 September.